Contents

1 Statistik **1**

1.1 Monte-Carlo Update 1
1.2 Rand-/Marginalverteilung 2
1.3 Abgeleitete Größen 2
1.4 Erwartungswerte 3
1.5 Schätzwerte 3
1.6 Fehler des Ensemble-Mittels 5
1.7 Schätzung der Varianz 7
1.8 Schätzung der integrierten Autokorrelationszeit 8

1 Statistik

Wir simulieren die Koordinaten

$$x_k = x(t_k)\,, \quad t_k = k\,a\,, \quad k = 0, \ldots, T/a - 1 = N_T - 1 \tag{1}$$

mit einer **Wirkung** $S(x_0, \cdots, x_{N-1})$ und periodischer Randbedingung $x_0 = x_N$.

Zu jeder Zeit t_i gehöhrt eine Zufallsvariable X_i. X_i kann beliebige reelle Werte annehmen. Zur Zufallsvariablen X_i gibt es eine **Wahrscheinlichkeitsverteilung** f_i. Die Wahrscheinlichkeit, dass X_i eine Wert im kleinen Intervall $x + dx$ annimmt ist dann

$$P\left(X_i \in [x,\, x + dx]\right) = f_i(x)\, dx \tag{2}$$

und wir nennen f_i die **(Wahrscheinlichkeits-)Dichtefunktion**. Es gilt immer die Normierung

$$\int_{-\infty}^{\infty} f_i(x)\, dx = 1\,. \tag{3}$$

Beispiel: Für eine Gauss-verteilte Zufallsvariable X ist

$$f(x) = \frac{1}{2\pi\,\sigma^2}\, \mathrm{e}^{-(x-\mu)/(2\sigma^2)} \tag{4}$$

$$P(X \in (a,b)) = \int_a^b \frac{1}{2\pi\,\sigma^2}\, \mathrm{e}^{-(x-\mu)/(2\sigma^2)}\, dx\,. \tag{5}$$

Bei unserer Simulation haben wir nun N_T Zufallsvariablen $X_0, \cdots, X_{N_T-1}$ mit der **gemeinsamen Wahrscheinlichkeitsverteilung** gegeben durch das Pfadintegral

$$P\left(X_0 \in (x_0, dx_0)\ \&\ldots\&\ X_{N_T-1} \in (x_{N_t-1}, dx_{N_T-1})\right) = f(x_0, \ldots, x_{N_T-1})\ dx_0 \ldots dx_{N_T-1}$$

$$f(x_0, \ldots, x_{N_T-1}) = \frac{1}{\mathcal{N}}\, \mathrm{e}^{-S(x_0,\ldots,x_{N_T-1})} \tag{6}$$

$$\mathcal{N} = \int dx_0 \ldots \int dx_{N_T-1}\, \mathrm{e}^{-S(x_0,\ldots,x_{N_T-1})}$$

1.1 Monte-Carlo Update

Wir nennen eine **Konfiguration** ein Array $x^{(i)} = \left\{x_0^{(i)}, \cdots, x_{N_T-1}^{(i)}\right\}$.

In jedem Update ziehen wir eine neue Konfiguration $x^{(i)}$ nach der Verteilung f in Gl. (6). Dabei nehmen wir an, dass unsere Simulation thermalisiert ist.

Wir ziehen also in jedem Update reelle Werte für die Zufallsvariablen X_0, ..., X_{N_T-1}, und zwar immer nach der gleichen (gemeinsamen) Verteilung.

1.2 Rand-/Marginalverteilung

Was ist die Wahrscheinlichkeitsdichtefunktion einer einzelnen Variable X_i für einen festen Zeitindex i? Das ist die **Marginalverteilung**. Wenn wir uns nur für die Wahrscheinlichkeit interessieren, dass X_i Werte in einem Intervall $[x, dx]$ annimmt, dann können wir alle anderen Variablen ausblenden, sie können jeden beliebigen Wert annehmen, und wir können also über diese Variablen integrieren

$$\begin{aligned} P\left(X_i \in [x, dx]\right) &= f_{X_i}(x)\, dx \\ f_{X_i}(x) &= \frac{1}{\mathcal{N}} \int dx_0 \ldots \int dx_{i-1} \int dx_{i+1} \ldots dx_{N_T-1}\, \mathrm{e}^{S(x_0,\ldots,x_{N_T-1})} \end{aligned} \tag{7}$$

Genauso kann man auch Marginalverteilungen für zwei Zufallsvariablen X_i, X_k oder drei X_i, X_k, X_l mit $i \neq k \neq l \neq i$, usw. definieren, duch teilweise Integration über die verbleibenden Variablen.

1.3 Abgeleitete Größen

Wir interessieren uns nicht nur für die gesamte Konfiguration, sondern auch für andere **Funktionen der Zufallsvariablen** X_i, das sind abgeleitete Größen ("derived quantities").

Beispiel: Wir nehmen die Zufallsvariable $Y_i = g(X_0, \cdots, X_{N_T-1} = X_i^2$ für einen festen Zeitindex i.

Auch diese Variable Y_i hat wieder eine Wahrscheinlichkeitsverteilung f_{Y_i} und diese folgt auch aus der gemeinsamen Verteilung f.

Die Wahrscheinlichkeit dafür, dass Y_i einen Wert im Intervall (a, b) annimmt, ist gleich der Wahrscheinlichkeit, dass X_i in $g^{-1}((a, b))$ liegt, also im Urbild von (a, b) unter g. Damit folgt

$$P\left(Y_i \in (a, b)\right) = \int_a^b f_{Y_i}(y)\, dy P\left(X_i \in g^{-1}((a, b))\right) = \int_{g^{-1}((a,b))} f_{X_i}(x)\, dx \tag{8}$$

Das wird natürlich schnell kompliziert. Nur als Beispiel, das zeitlich gemittelte x mit Zufallsvariable

$$Y = \frac{1}{N_T} \left(X_1 + \ldots X_{N_T}\right) \tag{9}$$

hat schon eine sehr komplizierte Urbildmenge, obwohl die Variable "einfach" aussieht.

1.4 Erwartungswerte

Zu einer Zufallsvariablen X mit Verteilungsfunkton f_X können wir Erwartungswerte ausrechnen.

Z.B. von X selbst

$$\langle X \rangle = \int x\, f(x)\, dx \tag{10}$$

oder auch von Funktionen g der Zufallsvariablen X

$$\langle g(X) \rangle = \int g(x)\, f(x)\, dx \tag{11}$$

So bestimmen wir z.B. die **Varianz** von X

$$\mathrm{var}(X) = \langle X^2 \rangle - \langle X \rangle^2 \tag{12}$$

mit

$$\langle X^2 \rangle = \int x^2\, f(x)\, dx \tag{13}$$

1.5 Schätzwerte

Wir kennen die echten Erwartungswerte nicht! Wir könne Größen wie $\langle X \rangle$ oder $\langle X^2 \rangle$ nur abschätzen.

Das machen wir mit der Stichprobe der Konfigurationen, die wir aus der Simulation erhalten $x^{(1)}, \ldots, x^{(N_C)}$. Die Menge dieser Konfigurationen bezeichnen wir als ein **Ensemble**.

Wir haben dann also N_C Sätze von Zufallsvariablen $X_0^{(1)}, \cdots, X_{N_T-1}^{(1)}, \ldots, X_0^{(N_C)}, \cdots, X_{N_T-1}^{(N_C)}$.

Problem ist: Diese Zufallsvariablen sind im allgemeinen **alle nicht unabhängig voneinander**.

Innerhalb einer Konfiguration ist das klar, weil es ja eine gemeinsame Verteilung f gibt, und diese lässt sich **nicht faktorisieren** in

$$f(x_0, \ldots, x_{N_T-1}) = f_{X_0}(x_0) \times \ldots \times f_{X_{N_T-1}}(x_{N_T-1}) \tag{14}$$

Wenn das ginge, dann wären die Zufallsvariablen $X_0, \ldots, X_{N_T-1}$ unabhängig voneinander. Aber die Wirkung $S(x_0, \cdots, x_{N_T-1})$ verknüpft die nächsten Nachbarn. Kann man nicht als einfaches Produkt schreiben.

Dass die $X_i^{(k)}$ und $X_j^{(l)}$ nicht unabhängig voneinander sind für verschiedene Konfigurationen, also verschiedene $k \neq l$ liegt am Algorithmus, genau an der Markov-Kette, die hinter dem Metropolis-Algorithmus und dem Update steht.

Konfiguration $x^{(k+1)}$ folgt aus $x^{(k)}$ durch eine "kleine" Änderung. Das Wesen der Markov-Kette ist gerade, dass wir eine Übergangswahrscheinlichkeit $W(x \to y)$ angeben können, dafür, dass wir von Konfiguration $x^{(k)} = x$ im Schritt k zur Konfiguration $x^{(k+1)} = y$ nach einem Monte-Carlo Schritt kommen.

Die Idee der Schätzung ist, dass wir den Erwartungswert, hinter dem ein Integral steht durch eine Summe mit endlich vielen Summanden nähern können

$$\langle g(X) \rangle = \int g(x)\, f(x)\, dx \approx \sum_{k=1}^{N_C} g(x^{(k)})\, f(x^{(k)}) \tag{15}$$

Man kann dann zeigen, dass und wie die Summe gegen den wahren Erwartungswert konvergiert.

Wir erzeugen aber unsere Konfigrationen $x^{(k)}$ mit **Importance sampling**, d.h. in der Summe brauchen wir nicht mehr mit $f(x^{(k)})$ gewichten.

Für uns gilt der einfache Mittelwert

$$\langle g(X) \rangle \approx \frac{1}{N_C} \sum_{k=1}^{N_C} g(x^{(k)})\,. \tag{16}$$

Schätzer sind Funktionen der Zufallsvariablen, die wir festlegen können. Diese müssen allerdings sinnvoll sein. Wir wollen immer erreichen, dass

$$\frac{1}{N_C} \sum_{k=1}^{N_C} g(x^{(k)}) \overset{N_C \to \infty}{\longrightarrow} \langle g(X) \rangle \tag{17}$$

konvergiert. Ob das so ist, prüfen wir, indem wir den Erwartungswert der Schätzfunktion bilden.

Beispiel: Schätzer für $\langle X_i \rangle$ für einen Zeitindex i. Da nehmen wir einfach den Ensemble-Mittelwert

$$\bar{X}_i = \frac{1}{N_C} \sum_{k=1}^{N_C} X_i^{(k)} \tag{18}$$

Was ist der Erwartungswert von $\bar{X}_i$? Für alle Konfigurationen gilt dieselbe gemeinsame Verteilung f und damit auch dieselbe Marginalverteilung für $X_i^{(k)}$! Und der Erwartungswert is ein **lineare** Operation. Also

$$\langle \bar{X}_i \rangle = \frac{1}{N_C} \sum_{k=1}^{N_C} \langle X_i^{(k)} \rangle = \langle X_i \rangle \tag{19}$$

Das Ensemblemittel ist also ein **erwartungstreuer Schätzer** von $\langle X_i \rangle$.

Beispiel: Schätzer für $\langle X_i^2 \rangle$. Dafür nehmen wir auch einfach

$$\bar{X_i^2} = \frac{1}{N_C} \sum_{k=1}^{N_C} X_i^{(k)\,2} \tag{20}$$

Wir prüfen den Erwartungswert

$$\langle \bar{X_i^2} \rangle = \frac{1}{N_C} \sum_{k=1}^{N_C} \langle X_i^{(k)\,2} \rangle = \langle X_i^2 \rangle \tag{21}$$

1.6 Fehler des Ensemble-Mittels

Wenn zwei Zufallszahlen X, Y mit gemeinsamer Verteilung $f_{XY}(x, y)$ **unabhängig** sind, dann gilt die Faktorisierung der Dichtefunktions

$$f_{XY}(x, y) = f_X(x)\, f_Y(y)\,. \tag{22}$$

Dann gilt für die **Korrelation** von X und Y, dass sie immer gleich Null ist

$$\begin{aligned}
\mathrm{cor}(X, Y) &= \langle (X - \langle X \rangle)\,(Y - \langle Y \rangle) \rangle = \langle X\, Y \rangle - \langle X \rangle\, \langle Y \rangle \\
&= \int f_{XY}(x, y)\, x\, y\, dx\, dy - \left[\int f_{XY}(x, y)\, x\, dx\, dy \right] \; \left[\int f_{XY}(x, y)\, y\, dx\, dy \right] \\
&= \int f_X(x)\, x\, dx \; \int f_Y(y)\, dy - \left[\int f_X(x)\, x\, dx \; \int f_Y(y)\, dy \right] \; \left[\int f_X(x)\, dx \int f_Y(y)\, y\, dy \right] \\
&= \langle X \rangle\, \langle Y \rangle - [\langle X \rangle \cdot 1] \; [1 \cdot \langle Y \rangle] = 0
\end{aligned} \tag{23}$$

Wenn die Zufallsvariablen **nicht unabhängig** sind, dann ist die Korrelation im Allgemeinen auch ungleich Null

$$\Gamma_{XY} = \langle (X - \langle X \rangle) \; (Y - \langle Y \rangle) \rangle \tag{24}$$

Wir berechnen den Fehler des Ensemble-Mittelwertes als **Wurzel aus der Varianz des Schätzers**

$$\delta \bar{x} = \sqrt{\mathrm{var}(\bar{X})} \tag{25}$$

Dazu berechnen wir zunächst die Varianz

$$\begin{aligned}
\mathrm{var}(\bar{X}_i) &= \langle \left(\bar{X}_i\right)^2 - \langle \bar{X}_i \rangle^2 \rangle \\
&= \langle \left(\frac{1}{N_C} \sum_{k=1}^{N_C} X_i^{(k)} \right)^2 - \langle \frac{1}{N_C} \sum_{k=1}^{N_C} X_i^{(k)} \rangle^2 \rangle \\
&= \langle \frac{1}{N_C^2} \sum_{k,l=1}^{N_C} X_i^{(k)} \, X_i^{(l)} - \langle X_i \rangle^2 \rangle \\
&= \frac{1}{N_C^2} \sum_{k,l=1}^{N_C} \langle X_i^{(k)} \, X_i^{(l)} - \langle X_i \rangle^2 \rangle \\
&= \frac{1}{N_C^2} \sum_{k,l=1}^{N_C} \langle \left(X_i^{(k)} - \langle X_i \rangle \right) \left(X_i^{(l)} - \langle X_i \rangle \right) \rangle
\end{aligned} \tag{26}$$

Fall 1: Die Konfigurationen sind unabhängig voneinander In diesem Fall gilt für die Korrelation von $X_i^{(k)}$ und $X_i^{(l)}$

$$\Gamma_{X_i^{(k)} \, X_i^{(l)}} = \begin{cases} \langle \left(X_i^{(k)} - \langle X_i \rangle \right)^2 \rangle = \mathrm{var}(X_i) \,, & k = l \\ \\ 0 \,, & k \neq l \end{cases} \tag{27}$$

Dann gilt für die Varianz in Gl. (26)

$$\mathrm{var}(\bar{X}_i) = \frac{1}{N_C^2} \sum_{k,l=1}^{N_C} \delta_{kl} \, \mathrm{var}(X_i) = \frac{1}{N_C} \, \mathrm{var}(X_i) \tag{28}$$

Damit gilt

$$\delta \bar{x} = \sqrt{\mathrm{var}(X_i)} \, \frac{1}{\sqrt{N_C}} \tag{29}$$

Der statistische Fehler ist also proportional zur **Wurzel aus der Anzahl der statistisch unabhängigen Messungen**.

Fall 2: Die Konfigurationen sind korreliert, also nicht unabhängig voneinander Dann definiert die Korrelation eine Funktion von $k - l$, also der Differenz in der Monte-Carlo-Zeit (= Simulations-Schritte).

$$\Gamma(k, \, l) = \langle \left(X_i^{(k)} - \langle X_i \rangle \right) \left(X_i^{(l)} - \langle X_i \rangle \right) \rangle \tag{30}$$

Wir Werten wieder die Varianz von $\bar{X}$ aus. Dabei benutzen wir, dass

- $\Gamma(k, \, l)$ ist nur eine Funktion von $k - l$

- $\Gamma(t)$ ist symmetrische unter $t \to -t$, also $\Gamma(t) = \Gamma(-t)$

$$\begin{aligned} \mathrm{var}(\bar{X}_i) &= \frac{1}{N_C^2} \sum_{k,l=1}^{N_C} \Gamma(k-l) \\ &= \frac{1}{N_C} \left\{ \Gamma(0) + 2\,\frac{N_C - t}{N_C} \sum_{t=1}^{N_C-1} \Gamma(t) \right\} \end{aligned} \tag{31}$$

Wir wissen, dass $\Gamma(t)$ für exponentiell abfällt. Das heißt die großen t-Werte tragen nur sehr wenig bei. Wenn N_C groß genug ist, dann können wir näherungsweise setzen

$$\mathrm{var}(\bar{X}_i) = \frac{2\,\Gamma(0)}{N_C} \left[\frac{1}{2} + \sum_{t=1}^{\infty} \frac{\Gamma(t)}{\Gamma(0)} \right] \tag{32}$$

Wir definieren damit die **integrierte Autokorrelationszeit** für die Variable X_i.

$$\tau_{\mathrm{int},X_i} = \frac{1}{2} + \sum_{t=1}^{\infty} \frac{\Gamma(t)}{\Gamma(0)} \tag{33}$$

Der Fehler unter Einbeziehung der **Autokorrelation der Konfigurationen untereinander** ist dann

$$\delta\bar{x} = \sqrt{\mathrm{var}(X_i)}\; \frac{1}{\sqrt{N_C/(2\tau_{\mathrm{int},X_i})}} \tag{34}$$

Es gilt also wieder: Der Fehler des Ensemble-Mittelwertes ist proportional zur Anzahl der unabängigen Messungen. Die Anzahl ist aber nicht N_C, sondern $N_C/(2\tau_{\mathrm{int},X_i})$.

1.7 Schätzung der Varianz

Um den Fehler von $\bar{x}$ zu berechnen, brauchen wir also die Varianz $\mathrm{var}(X_i)$. Diese kennen wir nicht, wir müssen sie wieder Abschätzen.

Dazu bauen wir uns einen Schätzer $\bar{V}$, angelehnt an die Formel für die Varianz $\mathrm{var}(X_i)$

$$\bar{V} = \frac{1}{N_C} \sum_{k=1}^{N_C} \left(X_i^{(k)} - \bar{X}_i \right)^2 \tag{35}$$

Wir prüfen wieder den Erwartungswert des Schätzers $\bar{V}$ in Gl. (35)

$$\begin{aligned}
\langle \bar{V} \rangle &= \langle \frac{1}{N_C} \sum_{k=1}^{N_C} \left(X_i^{(k)} - \bar{X}_i \right)^2 \rangle \\
&= \frac{1}{N_C^3} \sum_{k,l,m=1}^{N_C} \langle \left(X_i^{(k)} - X_i^{(l)} \right) \left(X_i^{(k)} - X_i^{(m)} \right) \rangle \\
&= \frac{1}{N_C^3} \sum_{k,l,m=1}^{N_C} \langle \left([X_i^{(k)} - \langle X_i \rangle] - [X_i^{(l)} - \langle X_i \rangle] \right) \left([X_i^{(k)} - \langle X_i \rangle] - [X_i^{(m)} - \langle X_i \rangle] \right) \rangle \\
&\frac{1}{N_C^3} \sum_{k,l,m=1}^{N_C} \{ \Gamma(k-k) - \Gamma(l-k) - \Gamma(k-m) + \Gamma(l-m) \} \\
&= \Gamma(0) - \frac{1}{N_C^2} \sum_{l,k=1}^{N_C} \Gamma(l-k) - \frac{1}{N_C^2} \sum_{k,m=1}^{N_C} \Gamma(k-m) + \frac{1}{N_C^2} \sum_{l,m=1}^{N_C} \Gamma(l-m)
\end{aligned} \tag{36}$$

Fall 1: Die Konfigurationen sind unabhängig von einander Also ist $\Gamma(k-l) = \delta_{k,l}\,\Gamma(0)$. Es gilt dann

$$\langle \bar{V} \rangle = \Gamma(0) - \frac{1}{N_C}\,\Gamma(0) = \frac{N_C - 1}{N_C}\,\Gamma(0) \tag{37}$$

Der Schätzer in Gl. (35) ist also **nicht erwartungstreu**. Es gibt ein **Bias**, das mit $1/N_C$ gegen Null geht.

Wir können aber ganz einfach einen erwartungsgreuen Schätzer definieren:

$$\boxed{\bar{V} = \frac{1}{N_C - 1} \sum_{k=1}^{N_C} \left(X_i^{(k)} - \bar{X}_i \right)^2} \tag{38}$$

Fall 2: Mit Autokorrelation Dieser Fall ist wieder etwas schwieriger, weil τ_{int} ins Spiel kommt. Es gilt (mit den Annahmen wie bei der Def. der integrierten Autokorrelationszeit)

$$\langle \bar{V} \rangle \approx \left(1 - \frac{2\,\tau_{\text{int},X_i}}{N_C} \right) \text{var}(X_i) \tag{39}$$

Wir haben also hier wieder ein Bias, das aber mit $1/N_C$ gegen Null geht. Wir sind immer auf der sicheren Seite, wenn wir ein Anzahl von Konfigurationen haben

$$\boldsymbol{N_C \gg \tau_{\text{int}}}$$

erreichen.

1.8 Schätzung der integrierten Autokorrelationszeit

Machen wir das nächste Mal.